

# Compte Rendu des séances du 03/03 et 05/03

**Participants :** Aminata Coulibaly, Antonella Atterey, Franklin Sima, Thomas Gufflet

**Objectif des séances:** Finaliser l'analyse des attaques et des implémentations des algorithmes d'anonymisation.

## 1. Travaux Accomplis

- Consolidation de notre analyse sur les différentes techniques d'anonymisation et leurs vulnérabilités.
- Construction du tableau récapitulatif associant chaque méthode d'anonymisation aux attaques possibles et aux solutions d'implémentation.

## 2. Présentation du Tableau Synthétique

Le tableau ci-dessous synthétise les différentes techniques d'anonymisation étudiées, ainsi que leurs vulnérabilités potentielles. Il servira de base pour la suite du projet afin d'orienter nos choix de stratégies et de solutions.

**Remarque :** L'accent a été mis sur les attaques les plus pertinentes pour notre étude, notamment les risques de réidentification et les failles liées aux méthodes d'agrégation.

*(Voir tableau enfin de page)*

## 3. Tâches à Court Terme

- **Mise en application :** Tester les attaques identifiées sur les jeux de données et mesurer leur impact.
- **Préparation des livrables :** Structurer la présentation des résultats sous forme de rapport et de visualisations.
- Préparation du scénario principal de la compétition.
- Préparation des éléments clés en vue du scénario principal de la compétition.

## 4. Prochaines Étapes

- **Préparation de l'adaptation du code source** à notre projet, en identifiant les éléments à modifier et les fonctionnalités à ajouter.
- Planification d'une séance d'expérimentation sur Codabench pour exécuter les tests d'attaques.

**Prochaine Réunion : 07/03/2025**

Bien à vous,  
Aminata Coulibaly

| Méthode                 | Implémentation               | Explication                                                                             | Exemple                                                      | Attaque possible                               | Exemple d'attaque                                                                                          |
|-------------------------|------------------------------|-----------------------------------------------------------------------------------------|--------------------------------------------------------------|------------------------------------------------|------------------------------------------------------------------------------------------------------------|
| <b>Pseudonymisation</b> | Remplacement d'identifiants  | Remplacer les données sensibles par des identifiants uniques.                           | "Jean Dupont" → "ID_12345"                                   | <b>Réidentification</b> par <b>recoupement</b> | Associer une base pseudonymisée avec une base contenant des données en clair pour retrouver des identités. |
|                         | Hachage (SHA-256, bcrypt)    | Transformer une donnée en une valeur hachée pour masquer l'original.                    | Hachage d'une adresse email                                  | <b>Attaque par dictionnaire</b>                | Tester des valeurs hachées avec une base pré-calculée pour retrouver les données originales.               |
|                         | Tokenisation                 | Remplacement par un jeton unique sans lien direct avec l'original.                      | Un numéro bancaire remplacé par un token temporaire          | <b>Attaque par fréquence</b>                   | Identifier des individus rares en analysant les distributions.                                             |
| <b>k-Anonymat</b>       | Généralisation               | Remplacement d'une valeur précise par une plage plus large.                             | "12/07/1990" → "1980-1990"                                   | <b>Attaque par lien externe</b>                | Associer une base de patients anonymisée avec une autre base contenant des informations non anonymisées.   |
|                         | Suppression                  | Suppression de colonnes contenant des informations identifiantes.                       | Retrait des numéros de téléphone                             | <b>Attaque par homogénéité</b>                 | Si un groupe ne contient que des personnes atteintes d'une même maladie, celle-ci devient identifiable.    |
|                         | Fusion de quasi-identifiants | Regroupement de valeurs similaires pour limiter la précision.                           | "Développeur back-end" → "Informatique"                      | <b>Attaque par composition</b>                 | Croiser des bases anonymisées pour retrouver des informations personnelles.                                |
| Agrégation              | Regroupement par catégories  | Remplacer des valeurs individuelles par des tranches ou des catégories.                 | "58 320 €" → "50 000 - 60 000 €"                             | <b>Attaque Airlock</b>                         | Soustraire deux requêtes légèrement différentes pour retrouver une valeur individuelle.                    |
|                         | Moyennisation                | Remplacer les données individuelles par des moyennes ou médianes.                       | Afficher uniquement la moyenne des salaires d'un département | <b>Attaque par différence</b>                  | Comparer une base avant et après anonymisation pour retrouver des valeurs modifiées.                       |
|                         | Ajout de bruit statistique   | Modifier légèrement les résultats des requêtes pour protéger les données individuelles. | Ajouter du bruit aux réponses des requêtes SQL               | <b>Attaque par homogénéité</b>                 | Si un groupe agrégé est trop homogène, certaines informations deviennent évidentes.                        |

