



La
pseudonymisation

Introduction

La pseudonymisation est une technique de protection des données personnelles qui remplace les identifiants directs (nom, adresse email) par des identifiants fictifs ou "pseudonymes".

Objectif

Réduire les risques liés à une violation des données tout en permettant certaines analyses ou traitements des données sans exposer directement les individus.

Méthodes de pseudonymisation

- **Hachage** : Transformation des données en une empreinte unique et fixe (SHA-256).
- **Tokenisation** : Substitution de données sensibles par un token aléatoire.
- **Cryptographie** : Utilisation de clés pour pseudonymiser et récupérer les données d'origine.

Ses failles

Cas Netflix (2006) :

Netflix a publié un ensemble de données pseudonymisées contenant les notes des utilisateurs sur des films. Des chercheurs ont pu réidentifier certains utilisateurs en croisant ces données avec celles disponibles sur IMDb (base publique).

Fuites des dossiers médicaux anonymisés d'Australie (2016) :

Le gouvernement australien a publié un ensemble de données pseudonymisées contenant les informations médicales de millions de patients, dans le but de promouvoir la recherche médicale.

Problème: Des chercheurs ont démontré qu'il était possible de réidentifier certains individus en combinant ces données avec des informations publiques, telles que des données démographiques et des événements spécifiques (hospitalisations).

Ses Limites et ses bonnes pratiques

Les Limites :

- La pseudonymisation n'élimine pas complètement le risque de réidentification, notamment en cas de croisement avec d'autres données.
- Elle nécessite des mesures de sécurité supplémentaires, comme le chiffrement des informations supplémentaires permettant de relier les pseudonymes.

Les Bonnes pratiques :

- Utiliser des algorithmes robustes de hachage et des clés sécurisées
- Limiter l'accès aux informations complémentaires nécessaires à la réidentification.
- Évaluer les risques de croisement avec d'autres jeux de données.