



Le k -anonymat

Introduction

Avec la montée en puissance des big data et la nécessité de partager des informations pour des analyses, tout en respectant les lois sur la protection des données comme le RGPD, il devient essentiel de protéger la confidentialité des individus. **Le k-anonymat est une technique d'anonymisation qui garantit qu'aucune personne ne puisse être identifiée de manière unique dans une base de données.**

Définition du k-anonymat

Le k-anonymat est une propriété d'une base de données anonymisée dans laquelle chaque individu est indistinguishable d'au moins **k-1** autres individus pour les attributs quasi-identifiants.

- **Attributs quasi-identifiants** : Ce sont des ensembles de données qui, isolément ou combinés, peuvent identifier un individu. Exemples : code postal, date de naissance, sexe.
- **Principe clé** : Si une base de données est k-anonyme, alors chaque individu est "camouflé" parmi au moins k-1 autres individus.

Techniques pour k-anonymisé

- **Généralisation** : consiste à rendre les attributs quasi-identifiants moins précis.

Par exemple : la date de naissance "**12/03/1990**" peut être généralisée en "**Mars 1990**" ou simplement "**1990**".

Le code postal "75001" peut être généralisé en "7500X" ou "75".

- **Suppression**: consiste à supprimer certaines valeurs ou lignes entières pour éviter les risques d'identification.

Par exemple, les valeurs trop spécifiques ou les enregistrements uniques peuvent être éliminés.

- **Équivalence**: regroupement des enregistrements en équivalences où chaque groupe contient au moins k enregistrements ayant les mêmes attributs généralisés.

Avantages du k-anonymat

- **Confidentialité garantie** : Il réduit considérablement le risque d'identification directe en rendant chaque individu indistinct parmi un groupe
- **Adaptabilité** : Peut être combiné avec d'autres techniques (e.g., suppression ou perturbation)

Failles du k-anonymat

- **Homogénéité des groupes** : Si tous les individus d'un groupe partagent la même valeur pour un attribut sensible, le k-anonymat n'empêche pas de deviner l'information sensible. Cela s'appelle **l'attaque par homogénéité**.
- **Attaque par fond croisé** : Un attaquant possédant des informations externes (e.g., sur un autre attribut) peut toujours identifier des individus.
- **Perte de précision** : La généralisation peut entraîner une perte importante de l'utilité des données pour les analyses.